



UNIVERZITET CRNE GORE  
PRIRODNO MATEMATIČKI FAKULTET

SEMINARSKI RAD

**Detekcija logičkih anomalija u 2D slikama uz pomoć f-AnoGAN  
modela**

Profesor:

Dr Igor Jovančević

Student

Teodora Đogović 5/24

Podgorica, 2025

## Sadržaj

1.	<b>Uvod.....</b>	<b>1</b>
2.	<b>Generativne adversarialne mreže (GAN) .....</b>	<b>2</b>
3.	<b>Od AnoGAN do f-AnoGAN.....</b>	<b>3</b>
4.	<b>Arhitekture treninga enkodera .....</b>	<b>4</b>
4.1.	<b>ziz arhitektura (latent → slika → latent).....</b>	<b>4</b>
4.2.	<b>izi arhitektura (slika → latent → slika).....</b>	<b>5</b>
4.3.	<b>izif arhitektura (diskriminator vođena).....</b>	<b>6</b>
4.4.	<b>Relacije s drugim radovima.....</b>	<b>7</b>
5.	<b>Detekcija i lokalizacija anomalija.....</b>	<b>8</b>
6.	<b>Detaljna metodologija i postavka eksperimenata.....</b>	<b>10</b>
6.1.	<b>Podaci i preprocesiranje.....</b>	<b>10</b>
6.2.	<b>Arhitektura mreža.....</b>	<b>11</b>
6.3.	<b>Protokol treninga.....</b>	<b>11</b>
7.	<b>Eksperimentalna evaluacija.....</b>	<b>11</b>
7.1.	<b>Evaluacija kvaliteta generisanih slika.....</b>	<b>11</b>
7.2.	<b>Detekcija anomalija na nivou slike.....</b>	<b>12</b>
7.3.	<b>Lokalizacija anomalija na nivou piksela.....</b>	<b>12</b>
8.	<b>Detaljna analiza rezultata.....</b>	<b>13</b>
8.1.	<b>Kvantitativna evaluacija detekcije anomalija.....</b>	<b>13</b>
8.2.	<b>Evaluacija lokalizacije anomalija.....</b>	<b>14</b>
8.3.	<b>Uporedna analiza arhitektura enkodera.....</b>	<b>15</b>
9.	<b>Ograničenja i budći pravci.....</b>	<b>16</b>
9.1.	<b>Ograničenja metode.....</b>	<b>16</b>
9.2.	<b>Budći pravci istraživanja.....</b>	<b>17</b>
10.	<b>Implementacioni detalji i reproduktibilnost.....</b>	<b>17</b>
11.	<b>Zaključna razmatranja.....</b>	<b>18</b>
12.	<b>Reference.....</b>	<b>19</b>

## 1. Uvod

U eri digitalne medicine, sve veći obim medicinskih snimaka nameće potrebu za razvojem automatizovanih algoritama koji mogu pomoći kliničarima u brzoj i preciznoj dijagnostici. Poseban izazov predstavlja detekcija anomalija – patoloških promjena koje odstupaju od normalne anatomije, a koje mogu biti indikatori različitih bolesti. Tradicionalni pristupi detekciji anomalija u velikoj mjeri se oslanjaju na nadgledano učenje, koje zahtjeva obimne anotirane skupove podataka. Međutim, stvaranje takvih skupova podataka je vremenski zahtjevno, skupo i često ograničeno na već poznate tipove lezija, što ograničava mogućnost otkrivanja novih, prethodno neopisanih patoloških stanja.

U ovom kontekstu, nenadgledano učenje predstavlja obećavajuću alternativu, jer omogućava modelima da uče normalne obrasce iz podataka bez potrebe za ekspertskim oznakama. Jedan od najinovativnijih pristupa u ovoj oblasti koristi generativne adversarialne mreže (GAN), koje imaju sposobnost da nauče distribuciju normalnih podataka i generišu veoma realistične sintetičke primjere. Polazeći od originalnog AnoGAN modela, koji je pokazao impresivne rezultate u detekciji anomalija, ali je bio ograničen sporim iterativnim procesom mapiranja, razvijen je f-AnoGAN (fast AnoGAN) kao revolucionarno rješenje koje dramatično ubrzava proces detekcije.

f-AnoGAN predstavlja naprednu arhitekturu koja kombinuje Wasserstein GAN sa gradijentnom kaznom i specjalizovanim enkoderom za brzo mapiranje slika u latentni prostor. Ova metoda ne samo da postiže vrhunsku tačnost u detekciji anomalija na nivou cijelih slika, već omogućava i preciznu lokalizaciju anomalija na nivou pojedinačnih piksela, što je od ključnog značaja za praktičnu primjenu u kliničkom okruženju. Kroz opsežnu evaluaciju na optičkoj koherentnoj tomografiji (OCT) snimcima mrežnjače, f-AnoGAN je demonstrirao superiorne performanse u odnosu na brojne alternative, uključujući autoenkodere, adversarialne autoenkodere i ALI modele.

U ovom radu ćemo detaljno istražiti teorijske osnove f-AnoGAN metodologije, analizirati njene arhitektonske komponente, i evaluirati njene performance kroz sistematske eksperimente. Posebnu pažnju posvetićemo poređenju različitih pristupa treningu enkodera (ziz, izi i izif arhitekture) i analizi njihovog uticaja na konačnu tačnost detekcije i lokalizacije anomalija. Kroz kritičku analizu rezultata i diskusiju ograničenja, cilj nam je da pružimo sveobuhvatan uvid u potencijal ove metode da transformiše praksu detekcije anomalija u medicinskoj imagistici i otvoriti nove mogućnosti za otkrivanje ranije neprepoznatih biomarkera bolesti.

## 2. Generativne adversarialne mreže (GAN)

Generativne adversarialne mreže (GAN) su uvedene od strane Goodfellowa et al. (2014) kao revolucionarni pristup generativnom modelovanju. GAN se sastoji od dve neuronske mreže:

- **Generator (G)**: stvara lažne podatke iz šuma (latentnog prostora).
- **Diskriminator (D)**: pokušava da razlikuje stvarne od generisanih podataka.

Ove dvije mreže se takmiče tokom treninga – generator nastoji da "prevari" diskriminatore, a diskriminatore postaje sve bolji u razlikovanju. Rezultat je da generator uči da proizvodi veoma realistične podatke.

U radu se koristi **Wasserstein GAN (WGAN)** sa gradijentnom kaznom (Gulrajani et al., 2017), što obezbeđuje stabilniji trening i bolje modele od klasičnih GAN-ova.

## 3. Od AnoGAN do f-AnoGAN

**AnoGAN** (Schlegl et al., 2017a) je prva GAN-bazirana metoda za detekciju anomalija. Ideja je da se GAN trenira samo na normalnim podacima. Za novi test primjer, traži se pozicija u latentnom prostoru čija generisana slika je što sličnija test slici. To se postiže iterativnim optimizacijama – što je sporo i neefikasno.

**f-AnoGAN** rješava ovaj problem uvodeći **enkoder** koji mapira slike direktno u latentni prostor u jednom prolazu, bez iteracija. Time se znatno ubrzava detekcija, što je ključno za real-time primjene.

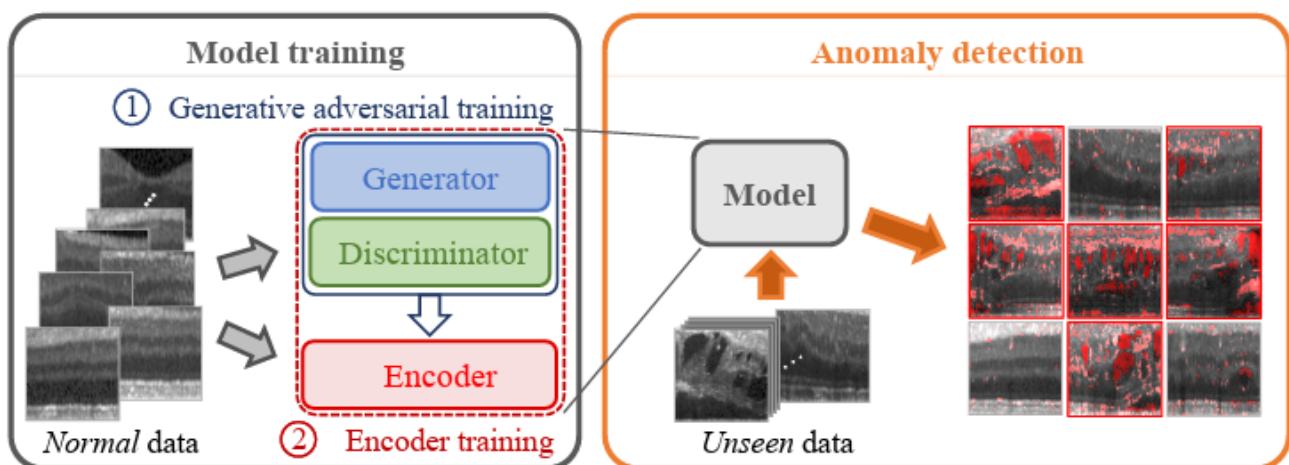


Figure 1 Okvir za detekciju anomalija. Oba koraka obuke modela — generativna adversarialna obuka i obuka enkodera — izvode se na normalnim podacima, a detekcija anomalija se zatim vrši i na neviđenim zdravim slučajevima i na anomalnim podacima.

## 4. Arhitekture treninga enkodera

f-AnoGAN koristi već istrenirani generator G (WGAN generator) i uči *enkoder* E koji mapira slike u latentni z-prostor tako da se brzo može naći odgovarajući z za novu sliku (bez iterativnog traženja). Postoje tri glavna načina za treniranje E:

**ziz** — treniranje E koristeći uzorke iz z-prostora i generisane slike  $G(z)$ . Dakle:

$$z \rightarrow G(z) \rightarrow E(G(z)) \approx z.$$

**izi** — treniranje E koristeći realne slike  $x$  i fiksni generator:  $x \rightarrow E(x) \rightarrow G(E(x)) \approx x$

**izif** — kao izi, ali uz dodatni član koji upoređuje *feature-prostor* diskriminatora D (dakle ne samo pikselna razlika, već i razlika u discriminator-featurama). To daje perceptualnu/realističniju mjeru razlike.

Sad detaljno o svakoj.

### 4.1. ziz arhitektura (latent → slika → latent)

Opis

- Generator G je fiksiran (već trenirani GAN generator).
- Uzima se nasumičan latentni vektor  $z \sim p(z)$  (npr. normalna ili uniformna distribucija).
- Prolazi se kroz generator da bi se dobila slika  $x_{gen} = G(z)$ .
- Enkoder E treba rekonstruisati originalni z iz te generisane slike:  $\hat{z} = E(G(z))$ .
- Cilj:  $\hat{z} \approx z$ .

Loss (formula)

$$L_{ziz}(z) = \frac{1}{d} \|z - E(G(z))\|^2$$

gdje je d dimenzionalnost latentnog prostora (broj komponenti u z). Ovdje norma označava euklidsku kvadratnu normu (sumu kvadrata razlika po komponentama).

Kako je dobijena formula

- MSE (mean squared error) u latentnom prostoru se koristi jer želimo da očekivana kvadratna greška po komponenti bude minimalna.

- Piše se eksplisitno kao prosjek ( $\frac{1}{d} \sum_{i=1}^d (z_i - \hat{z}_i)^2$ ), što normalizuje gubitak po dimenziji i olakšava poređenje pri mijenjanju d.

Gradijent i ko se uči

- G je fiksan. Parametri  $\theta_E$  enkodera se ažuriraju iz gradijenta:

$$\nabla_{\theta_E} L_{zi} = -\frac{2}{d} (z - E(G(z)))^\top \nabla_{\theta_E} E(G(z)).$$

- Gradijent teče samo kroz E (putem E i kroz mrežu na inputu G(z), ali bez promjene G).

Veliki nedostatak: enkoder nikad ne vidi realne slike tokom treninga, pa se može loše generalizovati kada mu se daju stvarne slike na inference-u. To je ključna slabost za anomaly detection na stvarnim podacima.

#### 4.2. Izi arhitektura (slika → latent → slika)

##### Opis

- Ovo je klasičan autoenkoder-stil: uzima se realna slika x iz dataset-a (normalne slike), enkodira se u  $\hat{z} = E(x)$ , a zatim se rekonstruiše slika kroz fiksni generator G:  $\hat{x} = G(E(x))$ .
- Cilj: rekonstruirana slika  $\hat{x}$  treba biti što sličnija originalu x.

##### Loss (formula)

$$L_{izi}(x) = \frac{1}{n} \|x - G(E(x))\|^2$$

gdje je n broj piksela. Norma opet znači suma kvadrata piksel-po-piksel.

##### Kako je dobijena formula

- Standardni MSE u *image*-prostoru: prosjek kvadratnih razlika po svim pikselima.
- Cilj minimizovati pikselnu razliku jer kod iz koje se generiše treba vratiti sličnu sliku.

##### Problemi i implikacije

- Taj loss nema direktnu informaciju o tome gdje u z-prostoru se nalazi "ispravan"  $\hat{z}$  jer stvarni z za sliku x nije poznat. Mjeri se samo koliko dobro G(E(x)) rekreira sliku.
- Enkoder je treniran na realnim slikama — to je plus.
- Međutim, pikselni MSE zna biti "loš" za realistične razlike: mali pomaci ili perceptualne razlike mogu dati veliku ili malu MSE vrijednost koja ne korelira sa realnošću slike. To

otežava anomaly detection posmatranjem samo pikselnog residuala (neka anomalija može imati mali pikselni residual ali vizualno biti nerealno).

### 4.3. Izif arhitektura (diskriminator vođena)

#### Motivacija

- MSE na nivou piksela iz izi ponekad daje lažno niske vrijednosti za anomalne slike (tj. slike koje nisu realne, ali imaju mali pikselni residual).
- Diskriminat D od GAN-a ima unutarnje feature (aktivacije u nekom srednjem hidden sloju) koje hvataju *visokorazinske* (perceptualne) statistike slike — one su empirijski jako dobre za razlikovanje realnih vs. nerealnih anomaličnih primjera.
- Ideja: osim MSE na nivou piksela koristimo i razliku u discriminator-feature prostoru kao dodatni gubitak. To pomaže da enkoder ne nauči mapirati slike sa anomalijama u z koje proizvode „pseudorealistične“ ali netačne slike.

#### Loss (formula)

$$L_{\text{izif}}(x) = \frac{1}{n} \|x - G(E(x))\|^2 + \frac{\lambda}{n_d} \|f(x) - f(G(E(x)))\|^2$$

gdje su:

- $f(\cdot)$  = vektor aktivacija nekog unutarnjeg (intermediate) sloja diskriminatora D (fiksani nakon WGAN treniranja),
- $n_d$  = dimenzionalnost tog feature-vektora,
- $\lambda$  težinski faktor koji uravnotežava važnost feature-gubitka u odnosu na pikselni gubitak.

#### Zašto dijeliti s $n_d$ i $n$ ?

- Dijeljenje s dimenzijom (normalizacija) čini termine uporedivim bez obzira na njihove prostore; to spriječava da jedan od članova dominira samo zato što ima više dimenzija.

#### Intuicija

- Prvi član  $\frac{1}{n} \|x - G(E(x))\|^2$  osigurava da je rekonstrukcija bliska po pikselima.
- Drugi član  $\frac{\lambda}{n_d} \|f(x) - f(G(E(x)))\|^2$  osigurava da rekonstrukcija sadrži *feature*-statistike koje diskriminat smatra karakterističnim za realne slike — dakle više perceptualne/teksturalne informacije.

- Kao rezultat, enkoder uči mapiranja koja su bolja i u pikselnom i u perceptualnom smislu.

#### **Odakle potiče ideja**

- Slično je feature-matching tehnici (Salimans et al.) i ideji perceptual loss (korištenje feature-space razlika umjesto/uz pikselnu razliku).
- U f-AnoGAN kontekstu, D je već dobro istreniran da prepoznaže “normalne” slike — njegove unutarnje aktivacije su zato dobar “sklop” perceptualnih karakteristika.

#### **Ko se uči**

- Kao i prije, G i D su fiksirani, trenira se samo E. D se koristi samo za računanje  $f(\cdot)$ , ne ažurira se.

#### **Prednosti / nedostaci**

- Kombinacija gubitka po pikselu i feature gubitka daje robustniji enkoder koji bolje rekonstruiše realne slike i izbjegava lažno male residue na anomalijama.
- Bolje detektuje anomalije jer discriminator features reaguju na nerealnosti.
- Potrebno je odabrati  $\lambda$ . Ako je  $\lambda$  prevelik, može se previše forsirati feature-poklapanje, a ako je premali onda nema efekta.
- Zavisnost o kvalitetu diskriminatora: ako je D loš, features neće biti korisni.

#### **4.4. Relacije s drugim radovima / zašto su ovi pristupi smisleni**

- **ziz** podsjeća na latent regressor u BiGAN/Adversarial feature learning (Donahue et al., 2016): ideja je direktno naučiti mapiranje iz slike u latent, ali tu su ciljevi poznati (jer se koriste generisani parovi  $z \leftrightarrow G(z)$ ).
- **izi** je klasični auto-encoder pristup, ali s fiksnim generatorom umjesto treniranog decoder-a. Prednost: enkoder uči iz stvarnih podataka.
- **izif** uvođenje discriminator-feature matching je empirijski motivisano — diskriminator u GAN-u lovi razliku između realne distribucije i generisanih primjera; njegove unutrašnje aktivacije su zato dobar “mjerni” prostor za realnost slike.

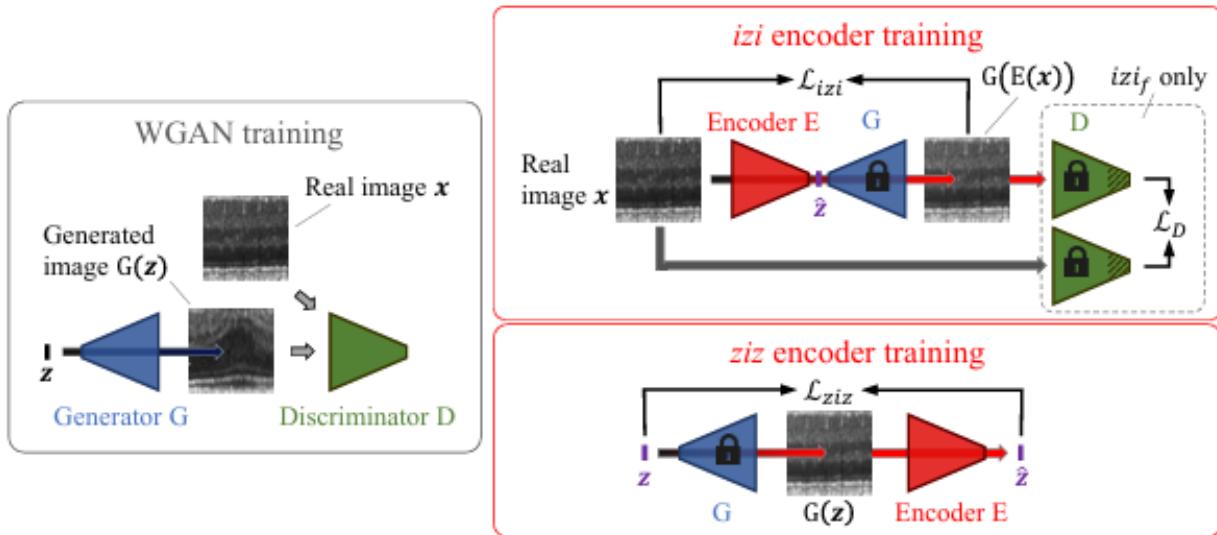


Figure 2 Tri moguće varijante obuke enkodera sa fiksiranim parametrima  $G$  i  $D$ , gdje se prilagođavaju samo parametri enkodera:  
1. izi obuka enkodera, 2. izif obuka enkodera 3. ziz obuka enkodera

## 5. Detekcija i lokalizacija anomalija

Anomalija se detektuje na osnovu **anomalija skora**:

$$A(x) = AR(x) + \kappa \cdot AD(x)$$

- AR: rekonstrukcioni gubitak u prostoru slika.
- AD: gubitak u feature prostoru diskriminatora.

Jedan od najznačajnijih doprinosa f-AnoGAN metode je njena sposobnost ne samo da detektuje prisustvo anomalija na nivou čitave slike, već i da precizno lokalizuje patološke promjene na nivou pojedinačnih piksela. Ova funkcionalnost ima ogroman klinički značaj jer omogućava ljekarima da direktno identifikuju i analiziraju specifične regije od interesa, umesto da se samo konstatiše postojanje anomalije.

### Mehanizam lokalizacije anomalija

Lokalizacija anomalija u f-AnoGAN sistemu zasniva se na konceptu rekonstrukcione razlike. Nakon što se ulazna slika propusti kroz enkoder i generator, dobija se rekonstruisana verzija originalne slike. Za normalne slike, ova rekonstrukcija bi trebala biti veoma slična originalu, budući da model dobro poznaje obrasce normalne anatomije. Međutim, kada se na ulazu nalazi anomalija (kao što je retinalni fluid), model će je "isparaviti" tokom rekonstrukcije, pokušavajući da je zamijeni najsličnjim normalnim sadržajem.

Matematički, lokalizacija se vrši korišćenjem apsolutne piksel-wise razlike između originalne i rekonstruisane slike:

$$\Delta R(x) = |x - G(E(x))|$$

Ova razlika se zatim koristi za generisanje heat mapa – vizuelnih reprezentacija gdje intenzitet boje odgovara stepenu anomalije svakog piksela.

### **Heat mape i njihov klinički značaj**

Heat mape predstavljaju ključni alat za interpretaciju rezultata lokalizacije. U kontekstu OCT snimaka mrežnjače:

- Crveni regioni na heat mapi označavaju područja sa najvećom rekonstrukcionom razlikom, što ukazuje na visoku vjerovatnoću prisustva anomalije
- Plavi regioni predstavljaju područja sa minimalnom razlikom, što odgovara normalnoj anatomiji
- Nijanse između pružaju gradiranu procjenu vjerovatnoće anomalije

Klinička vrijednost heat mapa ogleda se u nekoliko aspekata:

1. Precizno upućivanje: Ljekari mogu direktno da se fokusiraju na regije označene kao potencijalno patološke
2. Kvantifikacija obima: Omogućava mjerjenje veličine i obima anomalija tokom vremena
3. Praćenje terapijskog odgovora: Promjene u heat mapama mogu indicirati uspjeh ili neuspjeh lečenja

### **Praktični značaj za kliničku praksu**

Sposobnost precizne lokalizacije čini f-AnoGAN posebno korisnim za:

1. Ranu dijagnostiku: Detekcija malih, subkliničkih lezija koje mogu promaknuti ljudskom oku
2. Planiranje liječenja: Precizno odreditvanje obima i lokacije anomalija za ciljanu terapiju
3. Edukaciju: Vizuelizacija patoloških promjena za edukaciju mladih ljekara

Heat mape generisane f-AnoGAN metodom ne samo da pružaju binarnu segmentaciju već i probabilističku procjenu prisustva anomalije, što omogućava kliničarima da donose informisane odluke na osnovu stepena pouzdanosti modela.

Ova napredna funkcionalnost lokalizacije, kombinovana sa brzinom inferencije, pozicionira f-AnoGAN kao moćan alat za asistiranu dijagnostiku u savremenoj oftalmologiji i drugim granama medicinske imagistike.

## 6. Detaljna metodologija i postavka eksperimenata

### 6.1. Podaci i preprocesiranje

Istraživanje je koristilo **spektralni domen OCT (SD-OCT)** snimke mrežnjače prikupljene Heidelberg Spectralis uređajem. Svaki 3D volumen sastojao se od 49 poprečnih presjeka rezolucije  $496 \times 512 \times 49$  voksela. Primijenjeni su sljedeći koraci preprocesiranja:

1. **Normalizacija intenziteta** na raspon [-1, 1] po volumenu.
2. **Smanjenje rezolucije** sa 512 na 256 kolona (piksel veličine  $22\mu\text{m}$ ).
3. **Automatska segmentacija slojeva mrežnjače** (Garvin et al., 2009) za ekstrakciju i poravnavanje retinalnog područja.
4. **Ekstrakcija patch-eva** veličine  $64 \times 64$  piksela sa nasumičnih pozicija.

Ukupno je korišteno **270 volumena zdravih subjekata** za trening ( $\approx 850.000$  patch-eva), dok je test skup uključivao 10 zdravih i 10 oboljelih slučajeva sa prisutnim retinalnim fluidom.

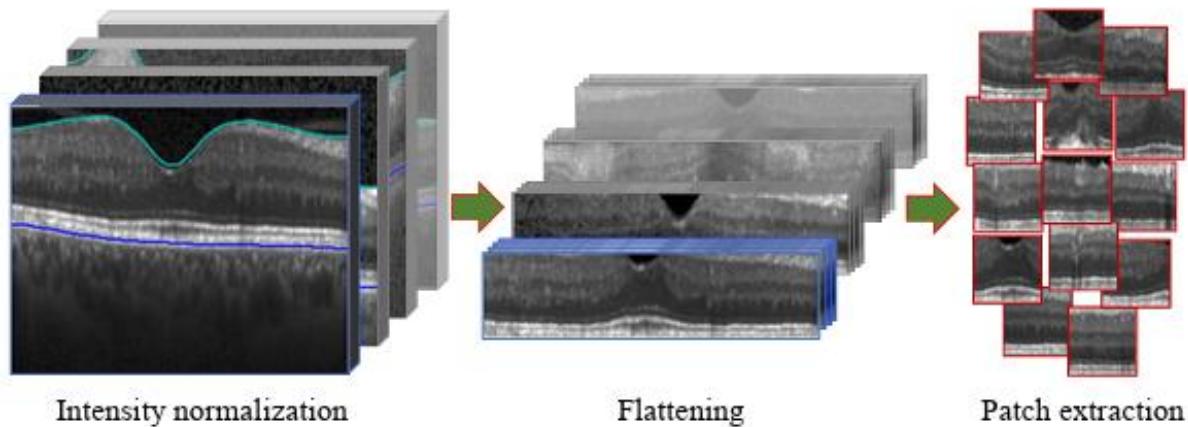


Figure 3 Predprocesiranje podataka. 1. Normalizacija intenziteta na nivoj volumena, 2. izdvajanje i izravnavanje retinalnog područja 3. izdvajanje 2D isečaka (patch-eva). (Najbolje se vidi u boji)

## 6.2. Arhitektura mreža

- **WGAN-GP** (Wasserstein GAN sa gradijentnom kaznom) korišten je sa **ResNet** arhitekturom.
- **Generator:** dekoder sa 4 residualna bloka ( $512 \rightarrow 256 \rightarrow 128 \rightarrow 64$  filtera).
- **Diskriminatore:** enkoder sa 4 residualna bloka ( $128 \rightarrow 256 \rightarrow 512 \rightarrow 512$  filtera).
- **Latentni prostor:** 128 dimenzija, normalna distribucija.
- **Enkoder:** slične arhitekture kao generator, ali sa tanh aktivacijom na izlazu za ograničavanje vrednosti.

## 6.3. Protokol treninga

1. **WGAN trening:** 100.000 iteracija (7 epoha), batch size 64.
2. **Trening enkodera:** 50.000 iteracija sa fiksnim generatorom i diskriminatorem.
3. **Optimizatori:** Adam za WGAN, RMSprop za enkoder.

## 7. Eksperimentalna evaluacija

Istraživanje je koristilo spektralni domen OCT (SD-OCT) snimke mrežnjače prikupljene Heidelberg Spectralis uređajem. Svaki 3D volumen sastojao se od 49 poprečnih presjeka rezolucije  $496 \times 512 \times 49$  voksela.

Primjenjeni su sljedeći koraci predprocesiranja:

1. **Normalizacija** intenziteta na raspon [-1, 1] po volumenu.
2. **Smanjenje rezolucije** sa 512 na 256 kolona (piksel veličine  $22\mu\text{m}$ ).
3. **Automatska segmentacija** slojeva mrežnjače (Garvin et al., 2009) za ekstrakciju i poravnavanje retinalnog područja.
4. **Ekstrakcija patch-eva** veličine  $64 \times 64$  piksela

### 7.1. Evaluacija kvaliteta generisanih slika

Dva klinička stručnjaka za retinu procenjivala su 100 slika (50 stvarnih, 50 generisanih). Rezultati:

- Tačnost razlikovanja: 0.44 (ispod slučajnog pogađanja)
- Konsenzus između procenjivača: 0.58

Ovo pokazuje da su generisane slike **vizuelno neprimetljive** od stvarnih OCT snimaka.

## 7.2. Detekcija anomalija na nivou slike

f-AnoGAN je upoređen sa:

- AE (autoencoder)
- AdvAE (adversarial autoencoder)
- ALI (Adversarially Learned Inference)
- Iterativni AnoGAN
- Samo diskriminator WGAN-a

Rezultati (AUC) su prikazani u tabeli 1:

**Tabela 1:** Uporedni pregled AUC metrike za različite modele

Model	AUC
AE	0.8688
AdvAE	0.8649
ALI	0.7897
Iterativni	0.9114
<i>f-AnoGAN</i>	<b>0.9301</b>

## 7.3. Lokalizacija anomalija na nivou piksela

U eksperimentima prikazanim u radu, f-AnoGAN je postigao AUC od 0.7831 za lokalizaciju retinalnog fluida, što predstavlja najbolji rezultat među upoređivanim modelima. Detaljna analiza pokazuje:

- Senzitivnost od 0.6907: Model uspešno detektuje 69% stvarnih anomalija
- Specifičnost od 0.7534: Samo 25% normalnih područja je pogrešno klasifikovano kao anomalije

- Manje lažno pozitivnih segmenacija: U poređenju sa ALI modelom i ziz arhitekturom, f-AnoGAN pokazuje značajno manje grešaka na granicama između mrežnjače i staklastog tela

## 8. Detaljna analiza rezultata

### 8.1. Kvantitativna evaluacija detekcije anomalija

U Tabeli 2 prikazane su performance različitih modela na **nivou slike**:

**Tabela 2:** Uporedni pregled tačnosti detekcije anomalija

	<b>Model</b>	<b>Preciznost</b>	<b>Senzitivnost</b>	<b>Specifičnost</b>	<b>F-score</b>	<b>AUC</b>
	<i>AE</i>	0.6824	0.7195	0.8550	0.7005	0.8688
	<i>AdvAE</i>	0.6405	0.7856	0.8092	0.7057	0.8649
	<i>ALI</i>	0.5063	0.7434	0.6863	0.6023	0.7897
	<i>A_D</i>	0.4909	0.6831	0.6931	0.5713	0.7504
	<i>Iterativni</i>	0.7202	0.8049	0.8645	0.7602	0.9114
	<i>f-AnoGAN</i>	<b>0.7863</b>	<b>0.8091</b>	<b>0.9049</b>	<b>0.7975</b>	<b>0.9301</b>

**Zapažanja:**

- f-AnoGAN postiže najbolje performance po svim metrikama.
- Iterativni pristup (AnoGAN) je tačan ali ekstremno spor (2 dana vs 20 sekundi za f-AnoGAN).
- Samo diskriminator (A\_D) daje loše rezultate, što ukazuje da je kombinacija rekonstrukcionog i feature gubitka ključna.

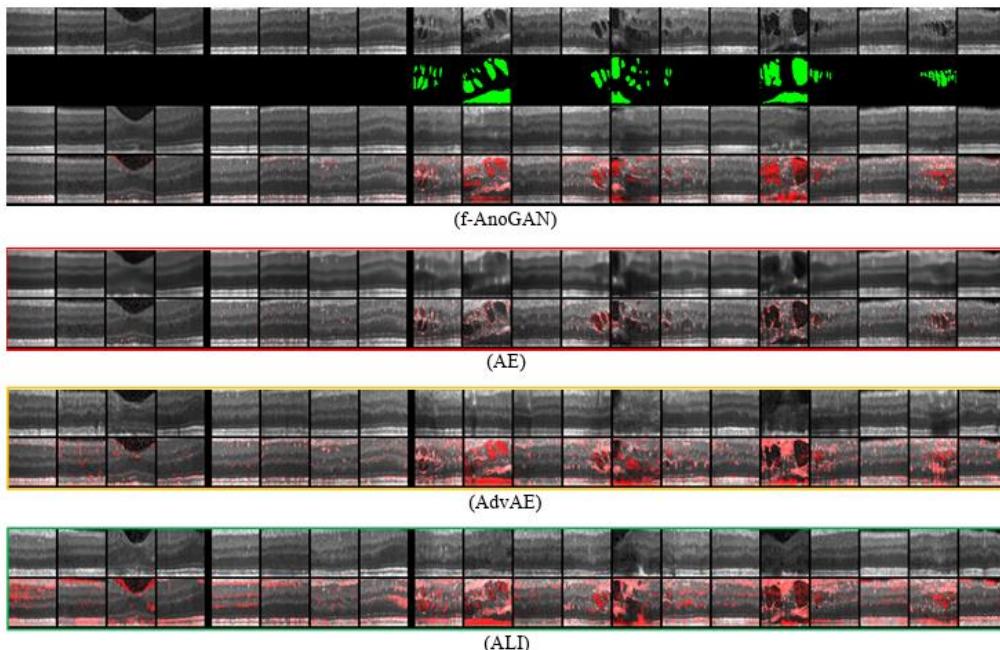
## 8.2. Evaluacija lokalizacije anomalija

Za lokalizaciju na nivou piksela, f-AnoGAN je upoređen sa AE, AdvAE i ALI modelima:

**Tabela 3:** Performance lokalizacije anomalija (retinalni fluid)

<b>Model</b>	<b>Senzitivnost</b>	<b>Specifičnost</b>	<b>AUC</b>
AE	<b>0.6960</b>	0.5428	0.6459
AdvAE	0.6284	0.7157	0.7195
ALI	0.6043	0.6468	0.6610
<b>f-AnoGAN</b>	0.6907	<b>0.7534</b>	<b>0.7831</b>

Iako AE ima nešto veću senzitivnost, f-AnoGAN ima znatno bolju specifičnost i ukupnu tačnost (AUC), što znači manje lažno pozitivnih segmenacija.



*Figure 4 Poređenje modela na nivou piksela u lokalizaciji anomalnih regiona na slikama. Prvi red prikazuje stvarne ulazne slike. Drugi red: anotacije anomalija na nivou piksela. Prvi blok: slike preuzete iz skupa za obuku. Drugi blok: normalne slike izdvojene iz zdravih slučajeva u testnom skupu. Treći blok: slike izdvojene iz oboljelih slučajeva u testnom skupu. Počevši od trećeg reda, u jednom redu prikazujemo generisane slike, a u pratećim redovima stvarne upitne slike sa preklapljenim rezidualom: Predloženi f-AnoGAN (redovi 3 i 4), AE (redovi 5 i 6), AdvAE (redovi 7 i 8), i ALI (redovi 9 i 10).*

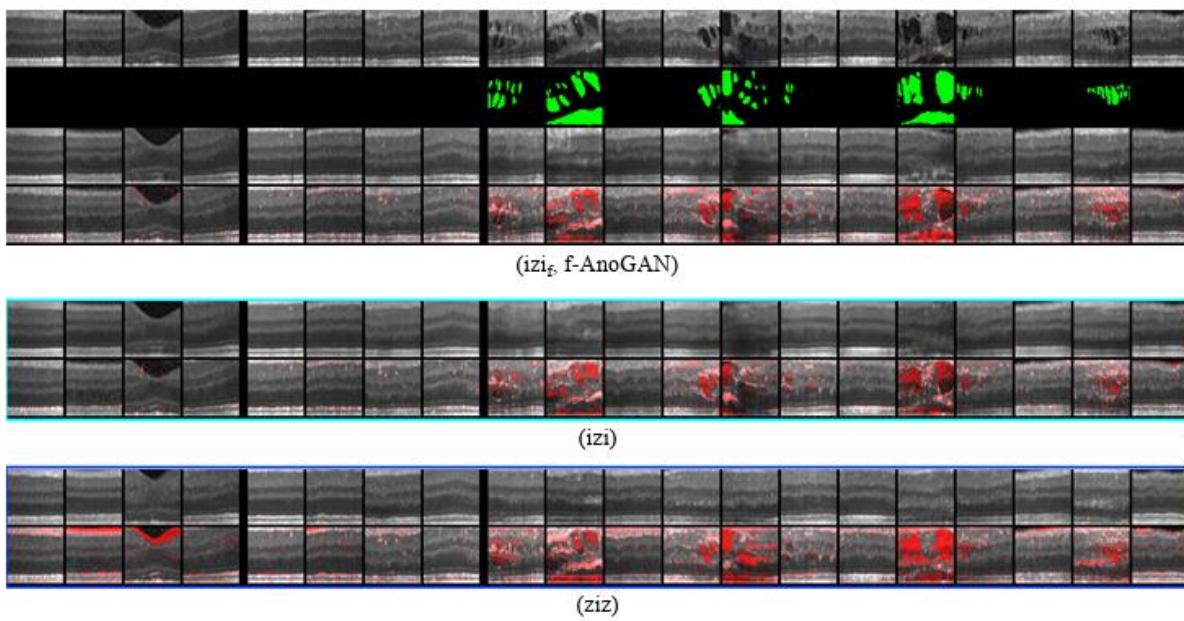


Figure 5 Poređenje obuke enkodera na nivou piksela u lokalizaciji anomalnih regiona na slikama. Počevši od trećeg reda, u jednom redu prikazujemo generisane slike, a u pratećim redovima stvarne upitne slike sa preklopjenim rezidualom: predloženi *f*-AnoGAN izif (r redovi 3 i 4), izi (redovi 5 i 6), i ziz (redovi 7 i 8) obuka enkodera. (Najbolje se vidi u boji)

### 8.3. Uporedna analiza arhitektura enkodera

**Tabela 4:** Performance različitih arhitektura enkodera

Arhitektura	Preciznost	Senzitivnost	Specifičnost	F-score	AUC
<i>ziz</i>	0.7047	<b>0.8146</b>	0.8522	0.7557	0.9066
<i>izi</i>	0.7018	0.7497	0.8621	0.7250	0.8874
<b>izif</b>	<b>0.7863</b>	0.8091	<b>0.9049</b>	<b>0.7975</b>	<b>0.9301</b>

Zaključci:

- *ziz* daje dobre rezultate ali ne vidi stvarne slike tokom treninga.
- *izif* (*f*-AnoGAN) daje najbolje performance zahvaljujući kombinaciji image i feature gubitka.

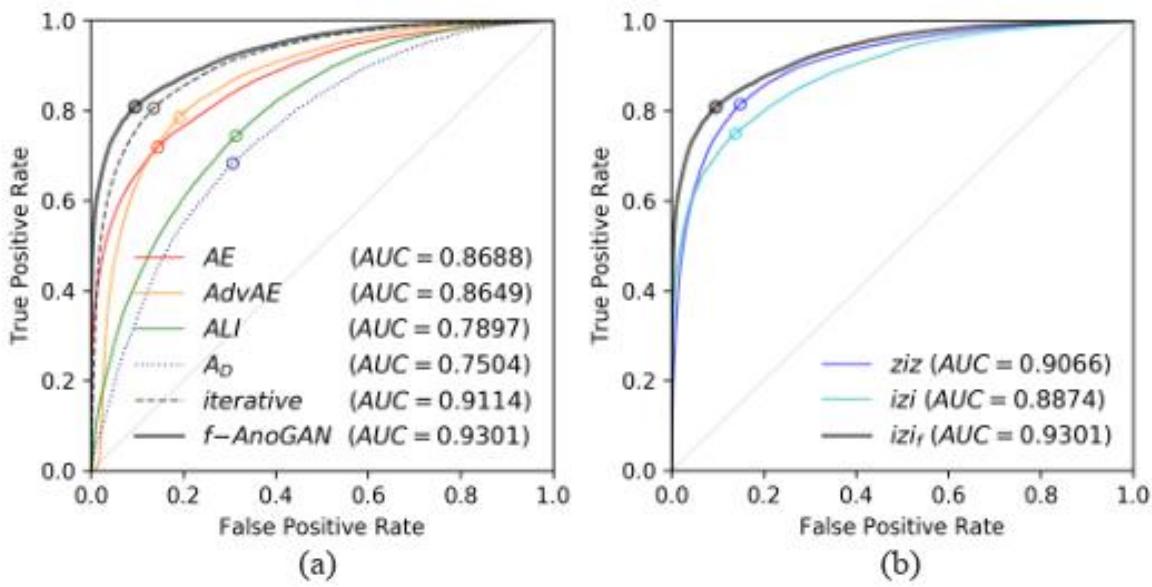


Figure 6 Evaluacija tačnosti detekcije anomalija na nivou slike. Poređenje različitih pristupa za detekciju anomalija na nivou slike na osnovu ROC krivih (receiver operating characteristic) i odgovarajućih vrijednosti površine ispod ROC krive (AUC), navedenih u zagradama. (a) Poređenje predloženog f-AnoGAN modela i alternativnih pristupa, AE (crveno), AdvAE (žuto), ALI (zeleno), direktno korišćenje izlaza diskriminatora istreniranog WGAN-a (AD, plava isprekidana linija), iterativno z-mapiranje zasnovano na istreniranom WGAN-u (kao u AnoGAN-u (Schlegl et al., 2017a), siva isprekidana linija), i predloženi f-AnoGAN model (sivo). (b) Poređenje različitih pristupa obuke enkodera zasnovanih na istom unaprijed istreniranom WGAN-u: ziz obuka enkodera (plavo), izi obuka enkodera (cijan), i izif obuka enkodera (sivo), koja je implementirana u predloženom f-AnoGAN modelu.

## 9. Ograničenja i budći pravci

### 9.1. Ograničenja metode

#### 1. Veličina patch-eva

Model operiše na malim patch-evima ( $64 \times 64$ ), dok kliničari donose procjene na nivou čitavog OCT presjeka. To znači da model vidi samo lokalne segmente, bez šireg anatomskega konteksta, što može dovesti do previda anomalija koje su vidljive tek u globalnoj strukturi slike.

#### 2. Nedostatak globalnog konteksta za logičke anomalije (glavno ograničenje)

Iako f-AnoGAN odlično detektuje strukturalne i teksturalno izrazite anomalije, značajno slabije se snalazi u slučaju logičkih (semantičkih) anomalija — onih koje ne odstupaju jasno u pikselima, ali narušavaju odnose između anatomskih struktura.

Primjer: sloj mrežnjače može izgledati normalno lokalno, ali može biti pomjeren, deformisan u kontekstu, ili može nedostajati očekivana simetrija.

Pošto GAN nauči prosječni izgled normalnih patch-ev, a ne pravila o globalnoj anatomiji, ove anomalije često ostaju neprepoznate.

#### 3. Nepotpune anotacije

Evaluacija je zasnovana samo na regionima koji su prethodno označeni kao lezije. Zbog toga se neki „lažno pozitivni“ slučajevi ustvari mogu odnositi na stvarne, ali neanotirane anomalije.

#### 4. Zavisnost od kvaliteta trening skupa

Metoda prepostavlja da su svi trening podaci potpuno normalni. Ako se u trening skupu pojave neprepoznate anomalije, model može naučiti pogrešnu distribuciju normalnog tkiva.

### 9.2. Budući pravci istraživanja

#### 1. Proširenje modela na čitave OCT presjeke

Umjesto obrade malih patch-eva, budući modeli bi trebali koristiti arhitekture koje mogu integrisati **globalne informacije** (npr. UNet, Vision Transformers, ili difuzioni modeli).

#### 2. Dodavanje modela za globalni kontekst (glavni smjer unapređenja)

Da bi se prevazišla slabost GAN pristupa u detekciji logičkih anomalija, preporučuje se kombinovanje f-AnoGAN-a s metodama koje razumiju **širu anatomiju i semantiku**, npr.:

- modeli zasnovani na **transformerima**, koji hvataju odnose između udaljenih piksela,
- dodatni **globalni autoenkoder** koji rekonstruiše cijelu sliku i poredi je s lokalnim GAN-rezidualima,
- hijerarhijski sistemi koji spajaju **patch-level** i **image-level** procjenu.

Ovakva hibridna rješenja mogu značajno poboljšati otkrivanje nepravilnosti koje nisu lokalno vidljive.

#### 3. Primjena na druge modalitete

Metodu bi trebalo evaluirati i na CT, MRI, fundusnim snimcima i histologiji, gdje su obrasci anomalija različiti i mogu otkriti nove slabosti ili prednosti modela.

#### 4. Integracija sa slabije nadgledanim pristupima

Kombinovanje nenadgledanog GAN učenja s djelimično anotiranim podacima može poboljšati modelovu sposobnost interpretacije i smanjiti zbunjenost između normalnih varijacija i stvarnih anomalija.

#### 5. Multi-modalno modelovanje

Uključivanje dodatnih izvora informacija (npr. klinički podaci, fundus kamera, AI segmentacija slojeva mrežnjače) može pomoći u otkrivanju šireg spektra biomarkera, uključujući i one suptilne ili semantičke.

## 10. Implementacioni detalji i reproduktibilnost

Autori su koristili:

- **TensorFlow 1.2** sa Python 2.7
- NVIDIA Titan X GPU
- Dostupnost koda na GitHub: <https://github.com/tSchlegl/f-AnoGAN>

Obezbeđena je potpuna reproduktibilnost eksperimenata sa detaljnim uputstvima za trening i evaluaciju.

## **11. Zaključna razmatranja**

f-AnoGAN predstavlja značajan pomak u oblasti nenadgledane detekcije anomalija u medicinskoj imagistici. Kroz kombinaciju naprednih GAN arhitektura i efikasnog mapiranja pomoću enkodera, ovaj model omogućava dobijanje visoko pouzdanih rezultata uz drastično smanjenje vremena inferencije u odnosu na klasični AnoGAN. Time se otvara prostor za realnu primjenu ovakvih sistema u kliničkim uslovima.

Jedan od ključnih razloga uspjeha f-AnoGAN-a jeste njegova sposobnost da precizno detektuje strukturalne anomalije, poput neočekivanih promjena u teksturi tkiva, lokalnih deformacija ili pojava koje odstupaju od normalne anatomske organizacije. Prema rezultatima više istraživanja iz oblasti medicinske analize OCT, MRI i CT podataka, modeli zasnovani na GAN-ovima generalno pokazuju odlične rezultate kada je potrebno identifikovati anomalije koje se „vizuelno“ razlikuju od zdrave strukture (npr. edemi, lezije, rupturi, tumorske mase).

Međutim, f-AnoGAN, kao i većina GAN-baziranih pristupa, nije uvijek optimalan za detekciju logičkih ili semantičkih anomalija — na primjer, onih koje nisu jasno vidljive u samoj teksturi slike, već zavise od šireg konteksta ili višeg nivoa interpretacije (npr. neuobičajeni odnosi između anatomske strukture, funkcionalne devijacije ili anomalije koje se ne manifestuju kao jasan morfološki obrazac). Ovakve situacije zahtijevaju modele koji bolje razumiju globalnu semantiku slike, poput naprednih autoenkodera sa semantičkim ograničenjima ili difuzionih modela.

Istraživanja objavljena nakon uvođenja f-AnoGAN-a ukazuju da GAN-ovi generalno najjače performanse pokazuju u detekciji anomalija tipa “nezavisnih od konteksta”, gdje se anomalni region značajno razlikuje od uobičajenog tkiva, dok su slabiji u slučajevima kada anomalijska struktura slično normalnoj strukturi, ali je „pogrešna“ u smislu funkcije ili logičkog rasporeda. Ovo je važno uzeti u obzir pri primjeni u realnim kliničkim scenarijima.

Zahvaljujući navedenim karakteristikama, f-AnoGAN omogućava:

- Skrining velikih skupova podataka u kliničkoj praksi, čime se rasterećuje rad radiologa i oftalmologa
- Brzu identifikaciju pacijenata s potencijalnim strukturnim abnormalnostima koje zahtijevaju dalju analizu
- Upotrebu u istraživačkim okruženjima za mapiranje normalno-patoloških obrazaca
- Integraciju u medicinske sisteme gdje je vrijeme obrade kritično (npr. urgentne dijagnostičke procedure)
- Otkrivanje novih biomarkera bez prethodnog znanja

Metoda je generalna i može se primeniti na različite tipove medicinskih i nemedicinskih podataka, što je čini važnim doprinosom u polju mašinskog učenja i medicinske informatike.

## 12. Reference

1. Schlegl, T., Seeböck, P., Waldstein, S. M., Langs, G., & Schmidt-Erfurth, U. (2019). f-AnoGAN: Fast unsupervised anomaly detection with generative adversarial networks.
2. Goodfellow, I., et al. (2014). Generative adversarial networks.
3. Gulrajani, I., et al. (2017). Improved training of wasserstein GANs.
4. Donahue, J., et al. (2016). Adversarial feature learning.
5. Zenati, H., et al. (2018). Efficient GAN-based anomaly detection.
6. Radford, A., Metz, L., & Chintala, S. (2015). Unsupervised representation learning with deep convolutional generative adversarial networks.